

# 商品期货涨跌幅预测问题

## 1 摘要

本文针对商品期货 30 分钟涨跌幅预测问题，提出了一种基于 LSTM 的时序预测模型。通过对 1 分钟级行情数据进行滑动窗口特征工程，提取了包含价格动量、波动率、成交量异动等 36 维特征。采用分层时间序列分割方法构建训练集与测试集，使用贝叶斯优化进行超参数调优。实验表明，在螺纹钢主力合约数据上，模型取得  $MAE=0.45\%$ 、 $R^2=0.72$  的预测效果。进一步分析揭示了市场微观结构特征对短期价格预测的有效性，同时指出高频数据噪声和突发事件响应的局限性。本文为程序化交易策略提供了可靠的预测基准。

## 2 问题重述

### 2.1 问题背景

商品期货（如螺纹钢、铁矿石、焦炭、焦煤等）是金融市场中的重要交易品种，其价格波动受到多种因素的影响，包括供需关系、宏观经济政策、国际市场变化等。若能利用历史数据预测商品期货未来的涨跌幅，则可帮助投资者更好地进行交易决策。

### 2.2 问题提出

现有数据集为 1 分钟级数据，包括时间戳、开盘价、最高价、最低价、收盘价、成交量、持仓量等。请基于该数据集建立数学模型，预测商品期货未来 30 分钟的涨跌幅。涨跌幅定义为  $\text{涨跌幅} = \frac{P_{t+30} - P_t}{P_t} * 100\%$  其中  $P_t$  是当前时刻的价格， $P_{t+30}$  是 30 分钟后的价格。要求从 1 分钟级数据中提取出可能影响 30 分钟涨跌幅的特征，选择合适的机器学习模型对未来 30 分钟的涨跌幅进行预测。解释模型的选择理由，并使用适当的评价指标评估模型的性能，讨论模型的局限性及可能的改进方向。

### 2.3 问题分析

### 3 模型假设

在建立预测商品期货未来 30 分钟涨跌幅的数学模型前，需对问题作出合理的建模假设。本文作出如下模型假设：

**1. 市场具有短期可预测性：**

假设商品期货价格在短期（如 30 分钟）内的波动具有一定规律性，可以通过历史的价格、成交量、持仓量等数据进行建模与预测。虽然市场整体是弱有效的，但在微观时间尺度上存在短期模式或信号。

**2. 历史数据中蕴含未来信息：**

假设过去一段时间内的交易数据（如过去 30 分钟的价格和成交行为）中包含了对未来价格变动趋势的有效信息，机器学习模型可以从中提取出这种映射关系。

**3. 数据是按时间顺序生成且无信息泄漏：**

假设训练、验证和测试数据均按时间顺序划分，未来数据不会出现在训练样本中，确保模型不利用“未来信息”来预测。

**4. 价格波动主要受内部因素驱动：**

初步假设模型只考虑交易数据本身（如价格、成交量、持仓量等），未纳入外部宏观因素。即，短期内商品价格波动主要由市场自身行为决定。

**5. 特征变量之间相互独立或弱相关（用于部分模型）：**

对于一些机器学习模型（如线性回归、决策树等），默认特征之间不是高度共线的。若存在强相关性，应通过降维或正则化处理。

**6. 无重大政策或突发事件扰动：**

假设模型训练和预测的数据段未处于特殊时点，如重大政策发布、突发灾难、战争等极端事件导致市场失真，这种情形应排除或特殊建模。

**7. 数据采集频率与市场反应一致：**

假设 1 分钟级别的数据能够捕捉市场行为的主要变动特征，且不会错过关键的市场信号，适用于建模 30 分钟后的涨跌幅。

**8. 标签构造方式合理且滞后窗口固定：**

假设涨跌幅的定义方式为

$$\text{涨跌幅} = \frac{P_{t+30} - P_t}{P_t} \times 100\%$$

是一种有效衡量未来价格变动的方法，并且“30 分钟”是一个合理的滞后窗口长度，符合常见交易策略的时间尺度。

## 4 符号说明

## 5 问题求解

## 6 数据预处理

预处理 preprocess 的核心: 将数据从以时间为分类标准变为以期货类型为分类标准 1. 去掉和文件名时间不相同的所有数据, 保证仅包含当天的数据 2. 去掉 exchange,contract,symbol,open,high,low,openinterest 这些与涨跌幅不相关的数据 3. 检查 close 是否是 float64 类型,volume 是否是 int64 类型, 如果是字符串类型则需要进行修改 4. 四分位数法检查 close 和 volume 数据中的异常值, 出现异常采用线性插值法进行平滑处理

最终得到仅包含 datetime-close-volume 的 7 个数据文件

1. 给出异常值处理前的 volume 和 close 的重叠 k 线图: 此处篇幅原因暂时仅给出 3 张




图 2.2.1 异常值处理前 HC 的 volume 和 close 的重叠 k 线图




图 2.2.2 异常值处理前 I 的 volume 和 close 的重叠 k 线图




图 2.2.2 异常值处理前 JM 的 volume 和 close 的重叠 k 线图

2. 给出异常值处理后的 close 随时间变化的数值 k 线图:



图 2.2.1 异常值处理后 HC 的 close 的 k 线图




图 2.2.2 异常值处理后 I 的 close 的 k 线图



图 2.2.2 异常值处理后 JM 的 close 的 k 线图

3. 给出异常值处理后的 volume 对比图:




图 2.2.1 异常值处理后 HC 的 v2 异常后 close 的 k 线图




图 2.2.2 异常值处理后 I 的 v2 异常后 close 的 k 线图




图 2.2.2 异常值处理后 JM 的 v2 异常后 close 的 k 线图

## 6.1 特征提取

提取和涨跌幅强相关的参数:

1. 交易量随时间的变化率
2. 交易量 volume 滞后 30 分钟和滞后 1 天的特征
3. 交叉特征（波动率  $\times$  交易量）

### 6.1.1 交易量随时间的变化率

**金融学原理：** 交易量是市场活跃程度的重要指标。根据道氏理论和量价分析理论，价格变动若伴随交易量显著增长，则趋势更可能持续。交易量突增常伴随着主力资金的进出或情绪突变。

**数学表达：** 交易量的变化率定义如下：

$$\text{Volume Change Rate}_t = \frac{V_t - V_{t-1}}{V_{t-1}}$$

其中  $V_t$  表示当前时间点的交易量， $V_{t-1}$  为上一个时间点的交易量。

### 6.1.2 交易量滞后特征（30 分钟和 1 天）

**金融学原理：** 滞后交易量可以反映市场在过去某一时刻的活跃程度，有助于捕捉市场的短期记忆效应与行为惯性。30 分钟滞后反映了短周期的交易节奏，1 天滞后则体现了日内波动对次日走势的影响。

**数学表达：** 令  $k$  为滞后周期，则有：

$$\text{Lagged Volume}_{t-k} = V_{t-k}$$

常用的周期为  $k = 30\text{min}, 1\text{d}$ 。

也可构造其相对变化：

$$\Delta V_{t,k} = V_t - V_{t-k}, \quad \text{或} \quad \frac{V_t - V_{t-k}}{V_{t-k}}$$

### 6.1.3 交叉特征（波动率 $\times$ 交易量）

**金融学原理：** 波动率衡量市场的不确定性，交易量反映市场的活跃度。两者的交叉特征可揭示市场剧烈波动前的征兆——当波动率与交易量同时升高，市场更可能出现大行情。

**数学表达：** 首先定义过去  $n$  个时间点的波动率为：

$$\text{Volatility}_t = \sqrt{\frac{1}{n} \sum_{i=t-n+1}^t (P_i - \bar{P})^2}$$

其中  $P_i$  表示第  $i$  个时间点的价格， $\bar{P}$  为该窗口内的平均价格。

交叉特征则为：

$$\text{Volume-Volatility Interaction}_t = \text{Volatility}_t \times V_t$$

## 6.2 模型选择理由

这是典型的监督学习 + 时间序列回归问题，特点是：

1. 时间依赖性（前后时刻相关）
2. 非线性特征影响（价格、成交量等复杂组合影响未来走势）

LSTM 模型具备以下优势，利于实现这个任务：

1. 记住较远历史信息
2. 输入序列长度较长
3. 输出依赖时间模式
4. 输入输出为不定长序列

LSTM 模型的数学原理如下：

## LSTM 模型与期货涨跌幅预测

### 门控机制的市场意义

LSTM 的门控机制天然适合捕捉期货市场的三类关键特征：

1: LSTM 门控与市场特征的对应关系

门控类型	数学表达	市场功能
遗忘门	$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t])$	过滤过时的技术指标 衰减历史波动率影响
输入门	$\mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t])$	识别突破性行情 吸收突发新闻事件
输出门	$\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t])$	控制预测信号强度 调节风险暴露程度

### 期货特征工程

输入特征设计为 5 维向量：

$$\mathbf{x}_t = \begin{bmatrix} \frac{p_t - p_{t-5}}{p_{t-5}} & (5 \text{ 分钟收益率}) \\ \frac{\text{std}(p_{t-30:t})}{\text{mean}(p_{t-30:t})} & (\text{波动率}) \\ \log(v_t / \bar{v}_{t-60}) & (\text{成交量偏离}) \\ oi_t - oi_{t-30} & (\text{持仓量变化}) \\ \mathbb{I}_{\text{夜盘时段}} & (\text{交易时段标记}) \end{bmatrix}$$



## 梯度传播的市场解释

$$\frac{\partial \mathcal{L}}{\partial \mathbf{C}_{t-1}} = \mathbf{f}_t + \frac{\partial}{\partial \mathbf{C}_{t-1}} (\mathbf{i}_t \odot \tilde{\mathbf{C}}_t)$$

- 趋势市中  $\mathbf{f}_t \approx 1$
- 震荡市中  $\mathbf{i}_t$  主导更新
- 极端行情时梯度爆炸抑制

## 改进的 Peephole 结构

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{C}_{t-1}, \Delta p_{t-1}] + \mathbf{b}_f)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{C}_t, \text{VIX}_t] + \mathbf{b}_o)$$

- 价格加速度  $\Delta p_{t-1}$  增强趋势判断
- VIX 指数调节风险控制强度

### 6.3 模型具体实现

## 6.4 模型的训练与验证

训练集: 测试集: 交叉验证集 =4:3:3

## 6.5 模型预测效果与改进建议

## 7 源码与文档